


Analisi della Produttività degli Sviluppatori AI

I M E A N ^ 2

Giada Scanga
Luca Timpano
Paolo Sicoli
Greta Tigano



IL DATASET

<https://www.kaggle.com/datasets/atharvasoundankar/ai-developer-productivity-dataset>

Il dataset descrive la produttività degli sviluppatori IA.
Contiene **500 osservazioni**, ognuna relativa a una giornata lavorativa, e diverse variabili riguardanti le abitudini lavorative e le performance.

Features

- **hours_coding**: le ore totali dedicate alla scrittura di codice
- **coffee_intake_mg**: quantità di caffeina assunta (in mg)
- **distractions**: numero di distrazioni durante il lavoro
- **sleep_hours**: ore di sonno
- **commits**: numero di salvataggi di codice effettuati
- **bugs_reported**: numero di errori segnalati
- **ai_usage_hours**: ore trascorse utilizzando strumenti di AI
- **task_success**: indicatore binario (0 o 1) del successo nel completamento dei compiti

Variabile Target

- **cognitive_load**: il carico cognitivo percepito o misurato (da 1 a 10)

	hours_coding	coffee_intake_mg	distractions	sleep_hours	commits
0	5.99	600	1	5.8	2
1	4.72	568	2	6.9	5
2	6.30	560	1	8.9	2
3	8.05	600	7	6.3	9
4	4.53	421	6	6.9	4

	bugs_reported	ai_usage_hours	cognitive_load	task_success
	1	0.71	5.4	1
	3	1.75	4.7	1
	0	2.27	2.2	1
	5	1.40	5.9	0
	0	1.26	6.3	1

ANALISI DESCRITTIVA

Prima della modellazione è stata effettuata un'analisi esplorativa dei dati:

GESTIONE DEI NULL

Non sono presenti valori nulli nel dataset

STATISTICHE DESCRITTIVE


	count	mean	std	min	25%	50%	75%	max
hours_coding	500.00	5.02	1.95	0.00	3.60	5.03	6.27	12.00
coffee_intake_mg	500.00	463.19	142.33	6.00	369.50	500.50	600.00	600.00
distractions	500.00	2.98	1.68	0.00	2.00	3.00	4.00	8.00
sleep_hours	500.00	6.98	1.46	3.00	6.10	6.95	7.90	10.00
commits	500.00	4.61	2.70	0.00	3.00	5.00	6.00	13.00
bugs_reported	500.00	0.86	1.10	0.00	0.00	0.00	2.00	5.00
ai_usage_hours	500.00	1.51	1.09	0.00	0.70	1.26	2.07	6.36
cognitive_load	500.00	4.50	1.87	1.00	3.18	4.40	5.80	10.00
task_success	500.00	0.61	0.49	0.00	0.00	1.00	1.00	1.00

OSSERVAZIONI

- *cognitive_load*: media (4,5) e mediana (4,4) sono quasi identiche. Questo suggerisce che la distribuzione di questa variabile sia molto equilibrata e simmetrica.
- lo sviluppatore medio passa circa 5 ore al giorno a scrivere codice
- gli sviluppatori dormono in media quasi 7 ore
- *task_success*: è una variabile binaria, dunque la sua media ci dice la percentuale di successo (61%)
- l'IA viene usata per circa un terzo del tempo dedicato al coding (1.5h su 5h), anche se c'è chi non la usa affatto (min = 0).

ANALISI DESCRITTIVA

I S T O G R A M M A D E L L A V A R I A B I L E D I P E N D E N T E



La distribuzione della variabile target *cognitive_load* appare:

- **unimodale**, con un picco intorno ai valori medi (circa 4,5).
- abbastanza **simmetrica**, ma con una leggera asimmetria positiva (la coda destra è più lunga)
- la densità sovrapposta suggerisce una forma complessivamente a campana

La forma complessiva è compatibile con una approssimazione normale.


MATRICE DI CORRELAZIONE

Dai dati emergono correlazioni più o meno forti tra coppie di regressori:

- **hours_coding - coffee_intake_mg (0.89)**: Il coefficiente di correlazione tra queste due variabili è estremamente vicino a 1.0 (tra le due esiste una relazione lineare quasi perfetta)
- **task success - coffee intake (0.70)**
- **commits - hours coding (0.65)**
- ...


Questa sovrapposizione "gonfia" la varianza dei coefficienti, rendendo le stime altamente instabili e inaffidabili.

$$\rho_{X,Y} = \frac{Cov(X, Y)}{\sigma_X \sigma_Y}$$




SCATTER PLOT

Lo scatter plot ci permette di evidenziare la forma delle relazioni che intercorrono tra le variabili, ed è coerente con quanto visto nella matrice di correlazione.




Scatter plot tra la variabile dipendente e i regressori



Scatter plot tra i singoli regressori

Matrice degli Scatter con Rette di Regressione



MODELLO LIN-LIN

$$CL = \beta_0 + \beta_1(HC) + \beta_2(CI) + \beta_3(D) + \beta_4(SH) + \beta_5(C) + \beta_6(BR) + \beta_7(AIH) + \beta_8(TS) + \epsilon$$

ANALISI DELLE METRICHE

- **R-squared (0.731)**: Indica che il modello spiega il 73.1% della varianza del carico cognitivo.
- **Prob (F-statistic) (1.23e-134)**: È un valore vicinissimo allo zero. Questo conferma che il modello nel suo complesso è estremamente significativo
- **p-value**: *sleep_hours*, *distractions* e *commits* sono variabili significative ($p < 0.05$), mentre le restanti non sembrano influenzare direttamente il carico cognitivo.
- **Durbin-Watson (1.843)**: il valore molto vicino a 2 indica che tra i residui non esiste autocorrelazione di primo ordine.
- **Condition Number (3.57e+03)**: questo valore estremamente alto suggerisce multicollinearità severa. Questo causa inaffidabilità sia delle stime che dei test di significatività dei singoli coefficienti.

OLS Regression Results



Dep. Variable:	cognitive_load	R-squared:	0.731
Model:	OLS	Adj. R-squared:	0.726
Method:	Least Squares	F-statistic:	166.6
Date:	Sun, 01 Feb 2026	Prob (F-statistic):	1.23e-134
Time:	14:57:36	Log-Likelihood:	-693.59
No. Observations:	500	AIC:	1405.
Df Residuals:	491	BIC:	1443.
Df Model:	8		
Covariance Type:	nonrobust		

	coef	std err	t	P> t	[0.025	0.975]
Intercept	9.4465	0.317	29.763	0.000	8.823	10.070
hours_coding	0.0074	0.058	0.127	0.899	-0.106	0.121
coffee_intake_mg	0.0001	0.001	0.155	0.877	-0.001	0.002
distractions	0.4751	0.026	17.985	0.000	0.423	0.527
sleep_hours	-0.9443	0.033	-28.233	0.000	-1.010	-0.879
commits	0.0426	0.021	1.991	0.047	0.001	0.085
bugs_reported	-0.0042	0.044	-0.096	0.923	-0.091	0.082
ai_usage_hours	0.0490	0.050	0.977	0.329	-0.049	0.147
task_success	-0.2182	0.136	-1.610	0.108	-0.485	0.048


Omnibus:	0.679	Durbin-Watson:	1.843
Prob(Omnibus):	0.712	Jarque-Bera (JB):	0.498
Skew:	0.046	Prob(JB):	0.780
Kurtosis:	3.125	Cond. No.	3.57e+03

NORMALITA' RESIDUI

- **QQ - plot:** gran parte dei punti si dispone lungo la diagonale a 45°, pertanto possiamo concludere che i residui si distribuiscono normalmente. Alcuni punti si staccano dalla linea agli estremi: ciò indica la presenza di outlier o code pesanti nella distribuzione dei residui, ma comunque siccome la parte centrale è allineata, l'adesione alla normale è da considerarsi valida.
- **Distribuzione dei residui:** segue la classica forma a campana, centrata sullo 0.



ETEROSCHEDASTICITÀ



- Distribuzione dei punti casuale → **INCORRELAZIONE**
- Attorno allo 0 → **MEDIA NULLA**
- Inizialmente si osserva una sorta di imbuto, ma la maggior parte degli errori si concentra in un intervallo ridotto → serve **test statistico** per rilevare con certezza eventuale eteroschedasticità

TEST BREUSH-PAGAN

Il test statistico conferma l'**assenza di eteroschedasticità**: il p-value risulta maggiore di 0.05, dunque si accetta l'ipotesi nulla di omoschedasticità degli errori.

Questo indica che i residui presentano **varianza costante** e supporta la validità delle inferenze OLS.

Il risultato è coerente con quanto osservato nel grafico dei residui, dove non emergono pattern sistematici. In particolare, il modello non tende a commettere errori più grandi o più piccoli al variare dei valori delle variabili esplicative.

```
--- RISULTATI TEST DI BREUSCH-PAGAN ---  
Lagrange multiplier statistic : 10.2189  
p-value                       : 0.2500  
f-value                       : 1.2805  
f p-value                     : 0.2512
```

MODELLO LIN-LIN CON INTERAZIONI

Il modello stimato è il seguente:

$$\widehat{CL} = \beta_0 + \beta_1(HC \times SH) + \beta_2D + \beta_3SH + \beta_4TS$$

Dov'è viene considerata la correlazione tra ore di coding e ore di sonno.

ANALISI DELLE METRICHE

- **R-squared (0.729)**: Indica che il modello riesce a spiegare il 72.9% della varianza del carico cognitivo. Non si notano differenze con il modello senza interazioni.
- **Prob (F-statistic) (9.66e-139)**: Anche qui il valore è quasi zero. Questo conferma che il modello nel suo complesso è estremamente significativo
- **p-value**: *distractions*, *sleep_hours* e l'interazione *hours_coding:sleep_hours* sono significativi. ($p < 0.05$), mentre *task success* non sembra influenzare direttamente il carico cognitivo.
- **Durbin-Watson (1.841)**: il valore molto vicino a 2 indica che i residui sono indipendenti tra di loro
- **Condition Number (203)**: Rispetto al valore critico del modello precedente, qui assistiamo a un miglioramento. Un valore di 203 indica che la multicollinearità è stata fortemente ridotta, ma non risolta completamente

OLS Regression Results						
=====						
Dep. Variable:	cognitive_load	R-squared:	0.729			
Model:	OLS	Adj. R-squared:	0.727			
Method:	Least Squares	F-statistic:	332.6			
Date:	Sun, 01 Feb 2026	Prob (F-statistic):	9.66e-139			
Time:	14:57:38	Log-Likelihood:	-695.38			
No. Observations:	500	AIC:	1401.			
Df Residuals:	495	BIC:	1422.			
Df Model:	4					
Covariance Type:	nonrobust					
=====						
	coef	std err	t	P> t	[0.025	0.975]

Intercept	9.8463	0.226	43.496	0.000	9.401	10.291
hours_coding:sleep_hours	0.0117	0.004	2.773	0.006	0.003	0.020
distractions	0.4731	0.026	17.973	0.000	0.421	0.525
sleep_hours	-1.0026	0.034	-29.437	0.000	-1.070	-0.936
task_success	-0.2799	0.122	-2.302	0.022	-0.519	-0.041
=====						
Omnibus:	0.720	Durbin-Watson:	1.841			
Prob(Omnibus):	0.698	Jarque-Bera (JB):	0.529			
Skew:	-0.007	Prob(JB):	0.767			
Kurtosis:	3.159	Cond. No.	203.			
=====						

MODELLO LIN-LIN SENZA COFFE INTAKE

$CL = \beta_0 + \beta_1(HC) + \beta_2(D) + \beta_3(SH) + \beta_4(C) + \beta_5(BR) + \beta_6(AIH) + \beta_7(TS) + \epsilon$

ANALISI DELLE METRICHE

- **R-squared (0.731):** Indica che il modello spiega il 73.1% della varianza del carico cognitivo.
- **Prob (F-statistic) (8.71e-136):** È un valore vicinissimo allo zero. Questo conferma che il modello nel suo complesso è estremamente significativo.
- **p-value:** sleep_hours, distractions e commits sono variabili significative (p<0.05), mentre le restanti non sembrano influenzare direttamente il carico cognitivo.
- **Durbin-Watson (1.844):** il valore molto vicino a 2 indica che tra i residui non esiste autocorrelazione di primo ordine.

Condition Number (70.0): questo valore molto più basso del precedente suggerisce che la multicollinearità è stata quasi del tutto risolta, rendendo le stime e i test di significatività dei singoli coefficienti molto più affidabili.

OLS Regression Results

Dep. Variable:	cognitive_load	R-squared:	0.731
Model:	OLS	Adj. R-squared:	0.727
Method:	Least Squares	F-statistic:	190.8
Date:	Mon, 23 Mar 2026	Prob (F-statistic):	8.71e-136
Time:	17:59:36	Log-Likelihood:	-693.60
No. Observations:	500	AIC:	1403.
Df Residuals:	492	BIC:	1437.
Df Model:	7		
Covariance Type:	nonrobust		

	coef	std err	t	P> t	[0.025	0.975]
Intercept	9.4684	0.284	33.319	0.000	8.910	10.027
hours_coding	0.0137	0.041	0.335	0.738	-0.067	0.094
distractions	0.4751	0.026	18.004	0.000	0.423	0.527
sleep_hours	-0.9450	0.033	-28.527	0.000	-1.010	-0.880
commits	0.0426	0.021	1.992	0.047	0.001	0.085
bugs_reported	-0.0038	0.044	-0.086	0.932	-0.090	0.083
ai_usage_hours	0.0485	0.050	0.971	0.332	-0.050	0.147
task_success	-0.2093	0.123	-1.707	0.089	-0.450	0.032

Omnibus:	0.669	Durbin-Watson:	1.844
Prob(Omnibus):	0.716	Jarque-Bera (JB):	0.488
Skew:	0.044	Prob(JB):	0.783
Kurtosis:	3.125	Cond. No.	70.0

MODELLO LOG-LIN

$$\ln(CL) = \beta_0 + \beta_1(HC) + \beta_2(CI) + \beta_3(D) + \beta_4(SH) + \beta_5(C) + \beta_6(BR) + \beta_7(AI) + \beta_8(TS) + \epsilon$$

ANALISI DELLE METRICHE

- **R-squared (0.689)**: Indica che il modello spiega il 68.9% della varianza del carico cognitivo.
- **AIC (-125.3)**: un AIC negativo indica che il modello è molto efficiente nel bilanciare complessità e precisione.
- **Condition Number (3.57e+03)**: come nel modello precedente, questo valore alto conferma la presenza di multicollinearità tra i regressori.

```

=====
OLS Regression Results
=====
Dep. Variable:      log_cognitive_load      R-squared:      0.689
Model:              OLS                    Adj. R-squared:  0.684
Method:             Least Squares          F-statistic:     135.9
Date:               Sun, 01 Feb 2026       Prob (F-statistic): 2.85e-119
Time:               14:57:41              Log-Likelihood:   71.667
No. Observations:   500                   AIC:             -125.3
Df Residuals:       491                   BIC:             -87.40
Df Model:           8
Covariance Type:    nonrobust
=====

```

	coef	std err	t	P> t	[0.025	0.975]
Intercept	2.6515	0.069	38.600	0.000	2.517	2.786
hours_coding	0.0004	0.013	0.030	0.976	-0.024	0.025
coffee_intake_mg	-0.0001	0.000	-0.720	0.472	-0.000	0.000
distractions	0.0963	0.006	16.851	0.000	0.085	0.108
sleep_hours	-0.1885	0.007	-26.037	0.000	-0.203	-0.174
commits	0.0079	0.005	1.705	0.089	-0.001	0.017
bugs_reported	-0.0015	0.010	-0.155	0.877	-0.020	0.017
ai_usage_hours	0.0126	0.011	1.166	0.244	-0.009	0.034
task_success	0.0235	0.029	0.801	0.424	-0.034	0.081

```

=====
Omnibus:            19.494    Durbin-Watson:      1.880
Prob(Omnibus):      0.000    Jarque-Bera (JB):   21.624
Skew:               -0.433    Prob(JB):           2.02e-05
Kurtosis:           3.536    Cond. No.            3.57e+03
=====

```

MODELLO LOG-LOG

$$\ln(CL) = \beta_0 + \beta_1 \ln(HC) + \beta_2 \ln(C) + \beta_3 \ln(D) + \beta_4 \ln(SH) + \dots + \epsilon$$

ANALISI DELLE METRICHE

- **R-squared (0.662)**: È sceso rispetto al modello Lin-Lin (0.73). Questo ci suggerisce che la relazione tra le variabili nel dataset è più lineare che "esponenziale" o "a potenza".
- **Prob (F-statistic) (1.40e-110)**: È un valore vicinissimo allo zero. Questo conferma che il modello nel suo complesso è estremamente significativo
- **p-value**: *log_distractions*, *log_sleep_hours* ($p < 0.01$) e *log_commits* ($p = 0.024$) sono statisticamente significative.
- **Durbin-Watson (1.920)**: il valore molto vicino a 2 indica che i residui sono indipendenti tra di loro
- **Condition Number (177)**: Notiamo un miglioramento del C.N rispetto al modello lineare con tutte le variabili.

Dep. Variable:	log_cognitive_load	R-squared:	0.662
Model:	OLS	Adj. R-squared:	0.657
Method:	Least Squares	F-statistic:	120.3
Date:	Sun, 01 Feb 2026	Prob (F-statistic):	1.40e-110
Time:	14:58:32	Log-Likelihood:	51.167
No. Observations:	500	AIC:	-84.33
Df Residuals:	491	BIC:	-46.40
Df Model:	8		
Covariance Type:	nonrobust		
=====			
	coef	std err	t P> t [0.025 0.975]

Intercept	4.1251	0.237	17.369 0.000 3.658 4.592
log_hours_coding	-0.0155	0.069	-0.225 0.822 -0.151 0.120
log_coffee_intake_mg	-0.0371	0.046	-0.808 0.420 -0.127 0.053
log_distractions	0.3413	0.021	15.892 0.000 0.299 0.383
log_sleep_hours	-1.3604	0.057	-23.830 0.000 -1.473 -1.248
log_commits	0.0473	0.021	2.268 0.024 0.006 0.088
log_bugs_reported	0.0009	0.021	0.043 0.966 -0.040 0.041
log_ai_usage_hours	0.0422	0.029	1.439 0.151 -0.015 0.100
log_task_success	0.0455	0.041	1.108 0.269 -0.035 0.126
=====			
Omnibus:	15.439	Durbin-Watson:	1.920
Prob(Omnibus):	0.000	Jarque-Bera (JB):	16.038
Skew:	-0.412	Prob(JB):	0.000329
Kurtosis:	3.300	Cond. No.	177.
=====			

CONFRONTO

M O D E L L O L I N - L I N

- E' il modello cui corrisponde il massimo R^2 , il che significa che tra i modelli proposti è quello che spiega la maggior parte della variabilità totale.
- Il valore dell' R^2 è inoltre molto vicino all' R^2 corretto, il che vuol dire che il modello è ben specificato e le sue variabili sono significative.
- Il qq plot mostra che la distribuzione dei residui è molto vicina a una normale, rendendo inutile l'applicazione di trasformazioni logaritmiche per correggere l'asimmetria della distribuzione
- Togliendo il regressore "coffe_intake" il condition number diminuisce fino a toccare il valore 70.

L O G - L I N E L I N - L O G

- I modelli logaritmici vengono tipicamente utilizzati per linearizzare relazioni non lineari o per correggere fenomeni di eteroschedasticità.
- Nel caso in esame le trasformazioni logartmiche non hanno prodotto un miglioramento della varianza spiegata (R^2), dunque non vale la pena introdurre nel modello una maggiore complessità.

V E R D E T T O

Dato il rispetto della normalità e dell'omoschedasticità e del minor valore del condition number, il modello Lin-Lin senza il regressore coffe_intake è stato selezionato come miglior modello tra quelli analizzati. Tuttavia per evidenziare i risultati delle tecniche di regolarizzazione è stato scelto il modello lin-lin come base per la LASSO.

METRICHE DI MULTICOLLINEARITÀ

- Elevata correlazione tra coppie di regressori
- R^2 elevato in corrispondenza di p-value alti
- Condition number elevato ($3.57e+03$)



Sono tutti sintomi della presenza di **multicollinearità** nei dati. Per una diagnosi più approfondita generiamo le misure di multicollinearità

V I F , T O L E R A N C E E R J 0

	variabile	VIF	Tolerance	rj0
0	hours_coding	49.618159	0.020154	0.979846
1	coffee_intake_mg	55.738789	0.017941	0.982059
2	distractions	4.096917	0.244086	0.755914
3	sleep_hours	9.852544	0.101497	0.898503
4	commits	6.817888	0.146673	0.853327
5	bugs_reported	1.796194	0.556733	0.443267
6	ai_usage_hours	4.539769	0.220276	0.779724
7	task_success	5.255569	0.190274	0.809726

- Un VIF superiore a **10** è generalmente considerato il limite massimo di tolleranza; valori prossimi a 50 indicano una varianza dei coefficienti estremamente instabile.
- Le variabili coffee_intake_mg (VIF = 55.74) e hours_coding (VIF = 49.62) mostrano una **correlazione** patologica con gli altri predittori.
- Conclusioni analoghe si possono trarre dall'analisi di Tolerance e Rj0.

REGOLARIZZAZIONE

In presenza di forte correlazione tra i predittori (es. *hours_coding* e *coffee_intake*), le stime OLS diventano inefficienti, con errori standard elevati che rendono i test di significatività inaffidabili. Per risolvere questo introduciamo una penalità alla funzione di verosimiglianza per "restringere" i coefficienti, migliorando la precisione delle stime.

I modelli tipicamente utilizzati sono:

- **LASSO**: per la selezione automatica delle variabili (parsimonia).
- **Ridge**: per stabilizzare i coefficienti senza escludere predittori.
- **Elastic Net**: per gestire gruppi di variabili altamente correlate tramite un mix delle due penalità.

$$L_{\text{LASSO}}(\beta, \lambda) = (\mathbf{y} - \mathbf{X}\beta)^T (\mathbf{y} - \mathbf{X}\beta) + \lambda \sum_{j=1}^p |\beta_j|$$

$$L_{\text{RIDGE}}(\beta, \lambda) = (\mathbf{y} - \mathbf{X}\beta)^T (\mathbf{y} - \mathbf{X}\beta) + \lambda \sum_{j=1}^p \beta_j^2$$

$$L_{\text{ENet}}(\beta, \lambda_1, \lambda_2) = (\mathbf{y} - \mathbf{X}\beta)^T (\mathbf{y} - \mathbf{X}\beta) + \lambda_1 \sum_{j=1}^p |\beta_j| + \lambda_2 \sum_{j=1}^p \beta_j^2$$

REGOLARIZZAZIONE

A P P L I C A Z I O N E D E L L E 3 T E C N I C H E

Per individuare la configurazione ottimale per i 3 modelli:

- il dataset è stato suddiviso in **training set** (80%), utilizzato per addestrare i modelli, e **test set** (20%), utilizzato per valutare i modelli stimati.
- I dati sono stati **standardizzati** per non inficiare il processi di regolarizzazione
- Per ogni tecnica, il miglior parametro di penalità lambda è stato selezionato tramite **5-fold Cross-Validation**. Per Lasso e Ridge è stata esplorata una griglia di 100 valori distribuiti logaritmicamente tra 10^{-4} e 10^1 , mentre per l'Elastic Net è stato ottimizzato il parametro alfa testando una griglia di valori (0.1, 0.5, 0.7, 0.9, 0.95, 0.99, 1) per trovare il bilanciamento perfetto tra componenti Lasso e Ridge.
- L'efficacia dei modelli è stata misurata sul test set attraverso alcune metriche di valutazione (vedi slide seguenti)

```
--- VARIABILI MANTENUTE DA LASSO ---
```

	Feature	Coefficiente
2	distractions	0.769744
4	commits	0.099999
6	ai_usage_hours	0.035683
7	task_success	-0.057025
3	sleep_hours	-1.384350

```
--- VARIABILI RIMOSSE (ELIMINATE) ---
```

```
['hours_coding', 'coffee_intake_mg', 'bugs_reported']
```

```
--- ELASTIC NET: VARIABILI MANTENUTE ---
```




	Feature	ElasticNet
2	distractions	0.769661
4	commits	0.099886
6	ai_usage_hours	0.035602
7	task_success	-0.056888
3	sleep_hours	-1.384294

REGOLARIZZAZIONE

L'analisi conferma la superiorità dei modelli LASSO ed Elastic Net, con un R^2 di 0.69 sul test set. Il LASSO ha ottimizzato la parsimonia del modello escludendo 3 variabili ridondanti (*hours_coding*, *coffee_intake*, *bugs_reported*) e isolando i 5 regressori principali. Questo approccio ha risolto l'instabilità dovuta alla multicollinearità, identificando nel riposo e nelle distrazioni i fattori determinanti per il carico cognitivo e rendendo più stabile il modello per scopi predittivi.

R I S U L T A T I

	Modello	Miglior Alpha	R2 Test	Variabili Rimosse
0	LASSO	0.037649	0.691775	3
1	RIDGE	10.000000	0.686521	0
2	ELASTIC NET	0.037745	0.691781	3



MULTICOLLINEARITÀ POST LASSO

Il modello **LASSO** si conferma la scelta ottimale, risolvendo definitivamente la severa multicollinearità riscontrata nell'OLS iniziale.

Il **Condition Number** è diminuito da 3000 a un valore di 1.71 indicando che le 5 variabili “scelte” sono ora quasi perfettamente ortogonali, rendendo le stime dei coefficienti affidabili per l'interpretazione.

ANALISI METRICHE (TEST SET)

Modello	R2	AIC	BIC	Cond. Number	Var. Mantenate
LASSO	0.6918	-5.07	10.56	1.71	5
RIDGE	0.6865	2.62	26.07	6.35	8
ELASTIC NET	0.6918	-5.07	10.56	1.71	5



MISURE MULTICOL. DOPO LASSO

	variabile	VIF	Tolerance	rj0
0	distractions	3.914739	0.255445	0.744555
1	commits	4.577986	0.218437	0.781563
2	ai_usage_hours	3.381951	0.295687	0.704313
3	task_success	3.110836	0.321457	0.678543
4	sleep_hours	6.821852	0.146588	0.853412


RESIDUI POST LASSO

Grafico dei residui: calcolato sul test set. La nuvola di punti rimane casuale e limitata, dunque il modello regolarizzato è robusto.

Distribuzione dei residui: rimane approssimativamente normale, indicando che la rimozione dei predittori ridondanti non ha introdotto distorsioni significative.



CONFRONTO ORDINATE



La **distribuzione** dei punti mostra una buona adesione alla diagonale della predizione perfetta, indicando che il modello riesce a catturare in modo coerente il trend centrale dei dati.

La **dispersione** dei punti attorno alla linea appare complessivamente simmetrica e non evidenzia fenomeni marcati di eteroschedasticità, suggerendo che il modello mantiene una precisione simile sia per livelli bassi che alti di carico cognitivo.

È presente un **outlier** (osservato ~3.5, stimato ~1.3) evidente, che rappresenta un caso in cui la stima del modello si discosta maggiormente dal valore osservato. Situazioni di questo tipo possono ridurre leggermente il valore di R^2 , ma risultano comuni nei dataset reali.